



دانشگاه علم و صنعت
دانشکده مهندسی کامپیوتر

داکیومنت رابط کاربری UI

سامانه هوشمند عامل گرا برای تحلیل متون
پزشکی

(Agentic Medical NLP System)

نگارش:

امیرحسین امجدیان

اساتید محترم:

جناب آقای دکتر اعتمادی
جناب آقای دکتر مینایی

درس پردازش زبان‌های طبیعی (NLP)

نیمسال اول ۱۴۰۴-۱۴۰۵

فهرست مطالب

۱	مقدمه	۲
۲	فاز آموزش (Training)	۲
۱.۲	پیکربندی داشبورد	۲
۲.۲	گزارش آزمایش‌ها (Trials)	۳
۱.۲.۲	آزمایش اول: خط مبنا (Trial 1)	۳
۲.۲.۲	آزمایش دوم: افزایش ظرفیت یادگیری (Trial 2)	۵
۳.۲.۲	آزمایش سوم: تلاش برای همگرایی (Trial 3)	۶
۳	فاز استنتاج (Inference)	۶
۱.۳	روش‌های ورود داده	۷
۲.۳	تحلیل نمونه و پیش‌بینی مدل	۷
۳.۳	تفسیرپذیری و هوش مصنوعی توضیح‌پذیر (XAI)	۷
۱.۳.۳	تحلیل گرادیان کلمات (Word Attribution)	۸
۲.۳.۳	تفسیر بالینی هوشمند (AI Clinical Interpretation)	۸
۴.۳	تحلیل نمونه ناهماهنگ (Prediction Mismatch)	۹
۱.۴.۳	تشخیص و عدم قطعیت	۹
۲.۴.۳	واکاوی علت خطا با XAI	۹

۱ مقدمه

این سیستم یک عامل هوشمند (Agentic System) برای طبقه‌بندی متون پزشکی است که از مدل‌های زبانی بزرگ (LLM) به عنوان «رهبر ارکستر» (Orchestrator) برای مدیریت فرآیند آموزش استفاده می‌کند. رابط کاربری (UI) این سیستم با استفاده از فریم‌ورک Streamlit طراحی شده و دارای دو بخش اصلی عملیاتی است:

۱. فاز آموزش (Training): برای تنظیم خودکار هایپرپارامترها و آموزش مدل.

۲. فاز استنتاج (Inference): برای تست مدل و دریافت خروجی‌های تفسیرپذیر (XAI).

در ادامه، جزئیات هر بخش به همراه گزارش تصویری آزمایش‌های انجام شده آورده شده است.

۲ فاز آموزش (Training)

در این بخش، کاربر پیکربندی اولیه را انجام داده و عامل هوشمند (Agent) با بررسی تاریخچه آزمایش‌ها، بهترین استراتژی را پیشنهاد می‌دهد.

۱.۲ پیکربندی داشبورد

همان‌طور که در تصویر ۱ مشاهده می‌شود، پنل تنظیمات شامل موارد زیر است:

The screenshot displays the 'Medical NLP Agentic System' dashboard. It features two main sections: '1. Data Configuration' and '2. Budget & Constraints'. In the first section, users can set the CSV path (currently 'data/medical_ready.csv') and dataset split ratios (Train: 70%, Validation: 15%, Test: 15%). The second section allows setting the maximum trials (budget) to 42 and the maximum epoch limit to 5. A 'Start Orchestration' button is present, and a progress bar indicates the system is 'Initializing Agentic System (Seed: 42)'. Below this, a green bar shows 'Data Split Created: Train: 2541, Val: 545, Test: 545'. A blue bar indicates 'Orchestration Completed!'. At the bottom, there is a red button labeled 'STOP TRAINING NOW'.

شکل ۱: نمای کلی داشبورد تنظیمات آموزش

پارامترهای قابل تنظیم عبارتند از:

جدول ۱: پارامترهای پیکربندی در داشبورد

پارامتر	توضیحات
CSV Path	مسیر فایل داده‌ها که باید شامل ستون‌های text و label باشد.
Split Ratios	درصد تقسیم‌بندی داده‌ها برای آموزش، اعتبار‌سنجی و تست (مثلاً 70%، 15%، 15%).
Max Trials	تعداد کل آزمایش‌هایی که Agent اجازه انجام آن‌ها را دارد (بودجه آموزش). در اینجا روی 3 تنظیم شده است.
Random Seed	هسته تصادفی برای تکرارپذیری نتایج (مقدار 42).
Max Epoch Limit	محدودیت سخت برای تعداد Epochها که توسط کاربر اعمال می‌شود (در اینجا 5). حتی اگر LLM پیشنهاد بیشتری بدهد، این محدودیت اعمال می‌شود.

۲.۲ گزارش آزمایش‌ها (Trials)

در این اجرا، سیستم سه آزمایش متوالی را انجام داده است. در هر مرحله، Orchestrator بر اساس نتایج قبلی، پیشنهاد جدیدی ارائه می‌دهد.


۱.۲.۲ آزمایش اول: خط مبنا (Trial 1)

در اولین گام، مدل BioBERT به دلیل آموزش تخصصی روی متون پزشکی انتخاب شد.

❑ **استراتژی:** استفاده از LoRA برای تنظیم دقیق کارآمد (Parameter-Efficient).

❑ **تنظیمات:** نرخ یادگیری (lr) برابر با 5×10^{-2} ، اندازه دسته (Batch Size) برابر با 16 و تعداد 3 دور آموزش (Epoch).

❑ **استدلال LLM:** شروع با یک نرخ یادگیری ایمن برای جلوگیری از Overfitting و ارزیابی پتانسیل مدل.



شکل ۲: نمودار یادگیری و ماتریس درهم‌ریختگی برای آزمایش ۱

نتیجه: همان‌طور که در تصویر ۲ پیداست، مدل به دقت 48.26% رسید اما نمودارها نشان‌دهنده Underfitting هستند.


۲.۲.۲ آزمایش دوم: افزایش ظرفیت یادگیری (Trial 2)

با توجه به نتایج آزمایش اول، عامل هوشمند تصمیم به تهاجمی‌تر کردن پارامترها گرفت.

□ تغییرات: افزایش نرخ یادگیری به $2e - 4$ (ده برابر آزمایش قبل).

□ محدودیت کاربر: LLM پیشنهاد 15 دور آموزش (Epoch) را داد، اما توسط سیستم محدودیت کاربر روی 5 اعمال شد (Capped by user).

□ استدلال LLM: مدل قبلی کند همگرا می‌شد. آداپتورهای LoRA می‌توانند نرخ یادگیری بالاتری را تحمل کنند.



شکل ۳: بهبود دقت در آزمایش ۲ با افزایش Learning Rate

نتیجه: دقت به 53.39% افزایش یافت (تصویر ۳). با این حال، نوساناتی در Validation Accuracy پس از آپک اول دیده می‌شود که نشانه شروع ناپایداری است.


۳.۲.۲ آزمایش سوم: تلاش برای همگرایی (Trial 3)

در آخرین تلاش مجاز، سیستم سعی کرد بین پایداری و یادگیری تعادل ایجاد کند.

❑ **استراتژی:** حفظ تنظیمات موفق آزمایش دوم (BioBERT + LoRA) با همان نرخ یادگیری $2e - 4$.

❑ **هدف:** تلاش برای رسیدن به همگرایی بیشتر با افزایش تعداد اپک‌ها (که مجدداً توسط کاربر روی 5 محدود شد).

❑ **تحلیل ماتریس درهم‌ریختگی:** کلاس‌های دارای نمونه کمتر (مثل کلاس 7) همچنان چالش‌برانگیز هستند، اما کلاس‌های غالب (مثل کلاس 8) بهتر شناسایی شده‌اند.



شکل ۴: نتایج نهایی در آزمایش ۳

نتیجه نهایی: بهترین دقت در حدود 49.91% تثبیت شد. سیستم نشان داد که برای بهبود بیشتر نیاز به مدیریت عدم تعادل داده‌ها (Class Imbalance) دارد که در لاگ‌ها به آن اشاره شده بود.

۳ فاز استنتاج (Inference)

بخش دوم رابط کاربری مربوط به تست مدل نهایی است. اگرچه تصویری از این بخش ارائه نشده، اما طبق کدهای سیستم (NLP.txt)، این بخش دارای قابلیت‌های زیر است:

- ❑ **ورودی متن:** امکان تایپ دستی متن پزشکی یا انتخاب نمونه از مجموعه تست (Test Set).
- ❑ **معیارهای ارزیابی:** نمایش کلاس پیش‌بینی شده، میزان اطمینان (Confidence Score) و آنتروپی (میزان عدم قطعیت).
- ❑ **تفسیرپذیری (XAI):** استفاده از تکنیک Integrated Gradients برای هایلایت کردن کلمات کلیدی که منجر به تصمیم مدل شده‌اند.
- ❑ **توضیحات بالینی:** تولید یک گزارش متنی توسط LLM که توضیح می‌دهد چرا کلمات انتخاب شده از نظر پزشکی حائز اهمیت هستند.

۱.۳ روش‌های ورود داده

همان‌طور که در رابط کاربری مشخص است، دو روش برای تأمین داده‌های ورودی وجود دارد:

۱. **ورود دستی متن (Manual Text Input):** کاربر می‌تواند متن بالینی یا شرح حال بیمار را مستقیماً تایپ یا کپی کند.

۲. **انتخاب از مجموعه تست (Select from Test Set):** در این حالت، کاربر می‌تواند یکی از نمونه‌هایی که سیستم در مرحله تقسیم‌بندی داده‌ها (Data Split) برای تست کنار گذاشته است را انتخاب کند. این ویژگی امکان ارزیابی مدل روی داده‌های واقعی که در آموزش دیده نشده‌اند را فراهم می‌کند.

۲.۳ تحلیل نمونه و پیش‌بینی مدل


در تصویر ۵، نمونه شماره ۷ از مجموعه تست انتخاب شده است. این نمونه دارای برچسب واقعی (Ground Truth) کلاس ۳ است.

خروجی‌های مدل برای این نمونه عبارتند از:

□ **کلاس پیش‌بینی شده:** مدل به درستی کلاس ۳ را تشخیص داده است.

□ **میزان اطمینان (Confidence):** مقدار 37.95% که نسبتاً پایین است.

□ **آنتروپی (Entropy):** مقدار 1.3921 که نشان‌دهنده عدم قطعیت بالا (High Uncertainty) در تصمیم‌گیری مدل است. نمودار احتمالات نیز نشان می‌دهد که مدل بین کلاس ۱ و کلاس ۳ دچار تردید بوده است، اما نهایتاً کلاس صحیح را انتخاب کرده است.



شکل ۵: رابط کاربری بخش استنتاج: ورودی متن و نمودار احتمالات کلاس‌ها

۳.۳ تفسیرپذیری و هوش مصنوعی توضیح‌پذیر (XAI)

یکی از ویژگی‌های کلیدی این سیستم، قابلیت توضیح چرایی تصمیمات است. همان‌طور که در تصویر ۶ مشاهده می‌شود، سیستم از دو لایه برای تفسیر استفاده می‌کند:


با استفاده از الگوریتم‌هایی نظیر Integrated Gradients، کلماتی که بیشترین تأثیر را در انتخاب کلاس 3 داشته‌اند، هایلایت شده‌اند. رنگ زرد تیره‌تر نشان‌دهنده اهمیت بالاتر کلمه است. طبق داده‌های استخراج شده، کلمات کلیدی و وزن آن‌ها به شرح جدول ۲ است:

(Importance Score) امتیاز اهمیت	(Keyword) کلمه کلیدی
0.5195	Gastroesophageal
0.4484	Hypertension
0.3593	gastroesophageal (تکرار)

در نهایت، سیستم با استفاده از یک مدل زبانی بزرگ (LLM)، یک گزارش بالینی (Doctor's Note) تولید می‌کند که ارتباط بین کلمات کلیدی و تشخیص نهایی را توضیح می‌دهد.

در نمونه مورد بررسی (تصویر ۶)، هوش مصنوعی توضیح می‌دهد که:

این تفسیر نشان می‌دهد که مدل صرفاً بر اساس کلمات کلیدی تصمیم نگرفته، بلکه روابط معنایی پزشکی بین علائم (مانند خونریزی گوارشی و عدم تعادل) را درک کرده است.



۴.۳ تحلیل نمونه ناهماهنگ (Prediction Mismatch)

در کنار تشخیص‌های صحیح، بررسی مواردی که مدل در آن‌ها دچار خطا می‌شود (Misclassification) برای درک رفتار سیستم حیاتی است. در اینجا نمونه شماره 32 از مجموعه تست بررسی شده است.

۱.۴.۳ تشخیص و عدم قطعیت

همان‌طور که در تصویر ۷ مشاهده می‌شود، بین نظر مدل و برچسب واقعی اختلاف وجود دارد:

□ برچسب واقعی (Ground Truth): کلاس 1.

□ پیش‌بینی مدل (Predicted Class): کلاس 0.

نکته حائز اهمیت، متریک‌های نظارتی مدل است. میزان اطمینان (Confidence) تنها 41.99% است و آنتروپی 1.1661 ثبت شده که در محدوده High Uncertainty قرار دارد. این یعنی سیستم به کاربر هشدار می‌دهد که به این پیش‌بینی اعتماد کامل نکند و نیاز به بررسی انسانی است.

Medical NLP Agentic System

Automated Clinical Text Classification

Diagnostic Module (NLP)

Input Method:

Manual Text Input Select from Text Set

Select Sample:

Sample 32 (Label: 1) - REASON FOR CONSULTATION, Per...

Input Preview

Raw Text

REASON FOR CONSULTATION: Pericardial effusion. HISTORY OF PRESENT ILLNESS: The patient is an 84-year-old female presented to emergency room with shortness of breath, fatigue, and dizziness. Low-grade fever was noted last few weeks. The patient also has chest pain described as dull aching type in precordial region. No relation to exertion or activity. No aggravating or relieving factors. A CT of the chest was done, which shows pericardial effusion. This consultation is for the same. The patient denies any high blood pressure or diabetes, the pregnancies or surgery. Activity is fairly stable. CHRONIC RISK FACTORS: History of borderline hypertension. No history of tobacco use. Medication: Furosemide 40mg twice daily. No history of alcohol consumption. Social History: Smokes 10 cigarettes daily. Allergies: No known allergies. Vital Signs: BP 130/80 mmHg, HR 95 bpm, RR 18, SpO2 95% on room air. Physical Exam: JVP 4 cm, Lungs clear, S3 present, No murmurs, No edema. Labs: CBC, BMP, TSH, Lipid panel, Urinalysis, and ECG are pending.

Ground Truth: Class 1

Run Analysis

Analysis Complete

Predicted Class

0

Confidence

41.99%

Entropy (Uncertainty)

1.1661

Uncertainty Status: High Uncertainty (Caution Needed)



شکل ۷: نمونه شماره 32: عدم تطابق پیش‌بینی با واقعیت و هشدار عدم قطعیت بالا

۲.۴.۳ واکاوی علت خطا با XAI

برای درک اینکه چرا مدل کلاس 0 را انتخاب کرده است، به بخش تفسیرپذیری در تصویر ۸ مراجعه می‌کنیم. جدول ۳ کلمات کلیدی تأثیرگذار بر این تصمیم را نشان می‌دهد:


جدول ۳: کلمات کلیدی مؤثر در پیش‌بینی نمونه ۳۲

کلمه کلیدی (Keyword)	امتیاز اهمیت نسبی
coronary	1.000
Pericardial	0.7991
pericardial (تکرار)	0.6922
artery	0.4995
disease	0.3224

تفسیر بالینی هوشمند: گزارش تولید شده توسط AI Doctor (موجود در تصویر ۸) استدلال بسیار جالبی ارائه می‌دهد که نشان می‌دهد خطا ممکن است ناشی از ابهام در داده‌ها باشد، نه لزوماً ضعف مدل:

«شناسایی کلاس 0 (احتمال کم بیماری عروق کرونر) توسط مدل، با توجه به علائم بیمار منطقی است. اگرچه بیمار درد قفسه سینه دارد، اما آنزیم‌های قلبی منفی هستند و درد ماهیت "تیرکشنده مبهم" (dull aching) بدون عوامل تشدیدکننده فعالیت دارد. مدل تشخیص داده است که "افیوژن پریکارد" (pericardial effusion) که در تصویربرداری دیده شده، توجیه بهتری برای علائم است تا بیماری حاد عروق کرونر.»

این مثال نشان می‌دهد که سیستم قادر است با ارائه استدلال، به پزشک کمک کند تا بین "خطای مدل" و "پیچیدگی پزشکی" تمایز قائل شود.



شکل ۸: تحلیل XAI برای نمونه ۳۲: توجیه پزشکی برای انتخاب کلاس 0 برخلاف برجسب موجود